网页爬取

赵耀

大纲

- ▶ Html标签简要介绍
- ▶ Jsoup的使用

```
<html>
     <head>
     </head>
     <body>
              <div></div>
              <span></span>
              </body>
</html>
```

- •<html> 元素是 HTML 页面的根元素
- •<head>元素包含了文档的元(meta)数据
- •<title>元素描述了文档的标题
- •<body> 元素包含了可见的页面内容
- •<h1> 元素定义一个大标题
- •元素定义一个段落
- •a 这是一个链接 元素定义一个链接
- •img 元素定义一个图像
- •<div>元素是用于分组 HTML 元素的块级元素。用于布局
- •用来组合文档中的行内元素。标签提供了一种将文本的一部分或者文档的一部分独立出来的方式。
- •呈现表格化数据

属性	描述
class	为html元素定义一个或多个类名 (classname)(类名从样式文件引入)
id	定义元素的唯一id
style	规定元素的行内样式 (inline style)
title	描述了元素的额外信息 (作为工具条使用)

更多标签和属性

Html 标签大全

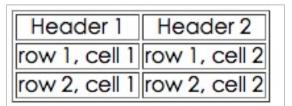
http://www.runoob.com/tags/html-reference.html

Html属性大全

http://www.runoob.com/tags/ref-standardattributes.html

```
Header 1
   Header 2
 row 1, cell 1
   row 1, cell 2
 row 2, cell 1
   row 2, cell 2
```

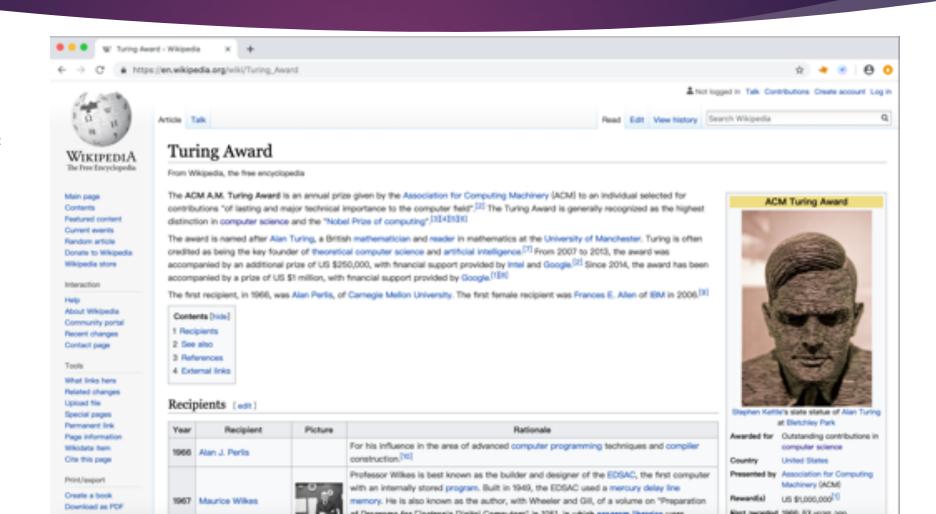
- 表格
- 表格的表头
- •表格中的一行
- •表格中的单元格



Jsoup

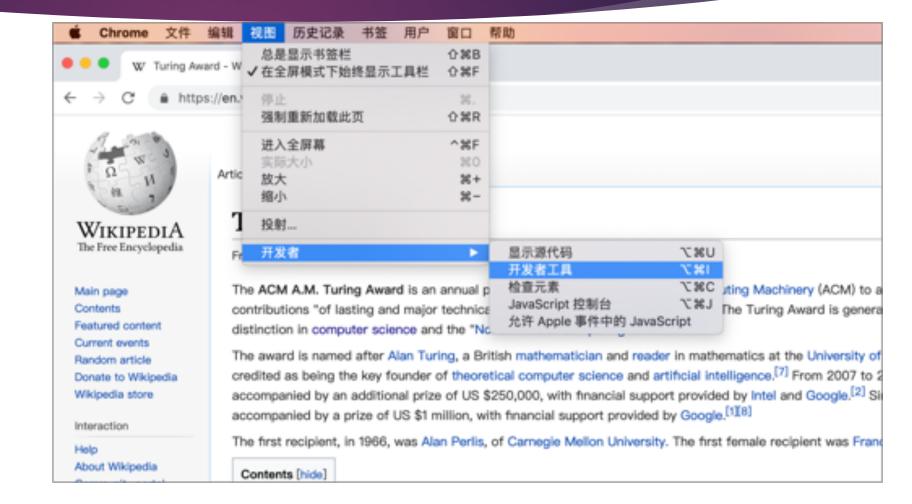
如何开始爬取网页?

先用chrome浏 览器打开想要爬 取的页面



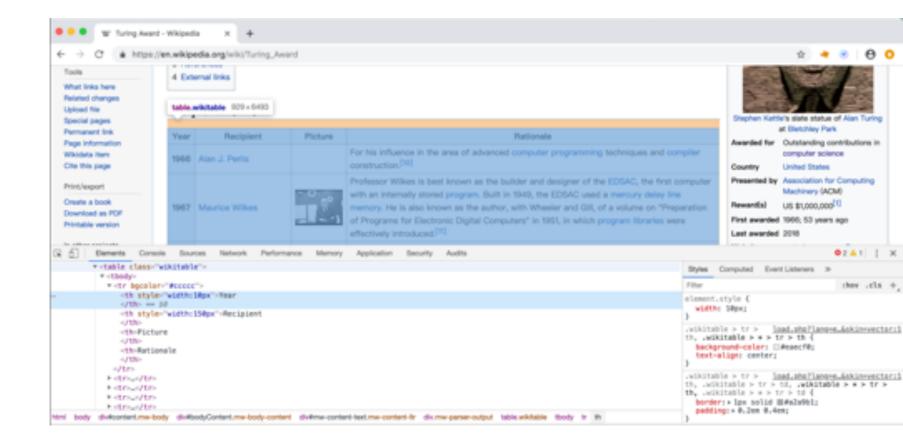
打开开发者工具

视图->开发者-> 开发者工具



分析待爬取内容

要爬取的内容为 table.wikitable



提取信息

▶ 逐级提取图灵奖获得者的信息,见ScrapingExample.java(课堂讲解代码)